

Fransa Motorlu Araç Sigorta Hasarları Raporu / French Motor Claims Report

Özet

Bu çalışmada, Fransa motorlu araç sigortaları pazarını temsil eden 678.013 poliçelik **FrenchMotorClaims** veri seti üzerinde aktüeryal risk analizi ve tarife modellemesi gerçekleştirilmiştir. İki aşamadan oluşan projenin ilk adımında, Python dili kullanılarak Keşifçi Veri Analizi (EDA) yapılmış; portföyün %95 hasarsız poliçelerden oluşan "Sıfır Yığılmalı" (Zero-Inflated) yapısı ve risk faktörlerinin doğrusal olmayan etkileri görselleştirilmiştir. İkinci aşamada ise R Studio ortamında istatistiksel hipotez testleri ve Genelleştirilmiş Doğrusal Modeller (GLM) kurgulanmıştır. Ki-Kare bağımsızlık testleri, araç yakıt türü (VehGas) ve yerleşim yeri yoğunluğunun (Area) hasar frekansı üzerinde istatistiksel olarak yüksek derecede anlamlı etkileri olduğunu kanıtlamıştır ($p < 0.05$).

Poisson GLM modelinde saptanan aşırı dağılım (overdispersion) problemi ($\text{dispersion} = 1.3049$, $p < 0.001$), varyans esnekliğine izin veren Negatif Binom Regresyon modeline geçilmesini zorunlu kılmıştır. Olasılık Oranı Testi (Likelihood Ratio Test), Negatif Binom modelinin veri setine uyum başarısının Poisson modeline kıyasla istatistiksel olarak devasa ölçüde üstün olduğunu ($\text{ChiSq} = 856.03$, $p < 2.2e-16$) doğrulamıştır. Ayrıca, poliçe aktiflik sürelerinin (Exposure) modele dengeleyici bir parametre (offset) olarak dahil edilmesinin model kalitesini radikal biçimde artırdığı saptanmıştır. Noktasal tahmin bazında RMSE değerleri başabaş çıksa da (Poisson: 0.2390, NB: 0.2390), artık analizi ve bilgi kriterleri (AIC) adil bir aktüeryal tarife yönetimi için Negatif Binom modelinin kullanılmasının bilimsel bir zorunluluk olduğunu ortaya koymuştur.

Anahtar Kelimeler: Aktüeryal Modelleme, Poisson GLM, Negatif Binom Regresyon, Aşırı Dağılım, Olasılık Oranı Testi, Maruziyet (Exposure).

Abstract

In this study, actuarial risk analysis and tariff structures are investigated using the **FrenchMotorClaims** dataset, which comprises 678,013 insurance policies from the French motor insurance market. In the first stage of this two-step project, Exploratory Data Analysis (EDA) was performed via Python, revealing a highly imbalanced, "Zero-Inflated" portfolio layout where %95 of the policies had zero claims, alongside non-linear behavior in key risk drivers. The second stage involved conducting parametric/non-parametric hypothesis tests and constructing Generalized Linear Models (GLM) in R Studio. Chi-Square tests of independence demonstrated that vehicle fuel type (VehGas) and population density (Area) exert a statistically significant impact on claim frequency ($p < 0.05$).

The formal overdispersion test executed on the baseline Poisson GLM pointed out a severe violation of the equidispersion assumption (dispersion = 1.3049, $p < 0.001$), justifying a structural shift toward a Negative Binomial Regression model. A Likelihood Ratio Test (odTest) confirmed that the Negative Binomial framework provides a massive and statistically superior fit over the Poisson baseline (Chisq = 856.03, $p < 2.2e-16$). Furthermore, incorporating the duration of policy validity (Exposure) as an offset parameter significantly improved model performance. Although point-prediction metrics yielded identical error rates (Poisson RMSE: 0.2390, NB RMSE: 0.2390), information criteria (AIC) and residual deviance diagnostics robustly concluded that the Negative Binomial model is the statistically sound and scientifically mandatory choice for equitable pricing and risk management.

Keywords: Actuarial Modeling, Poisson GLM, Negative Binomial Regression, Overdispersion, Likelihood Ratio Test, Exposure.

1.AŞAMA PYTHON İLE VERİ GÖRSELLEŞTİRME

Veri Setine Genel Bakış ve Keşifçi Veri Analizi (EDA)

Ne Yaptık?

Projenin ilk aşamasında, Fransa'daki araç poliçelerine ait **FrenchMotorClaims** veri setini projemize dahil ettik. Verinin yapısını anlamak için eksik değer kontrolü, satır/sütun sayıları ve değişken türleri incelenmiş; veri setinin özet istatistikleri çıkarılarak temizleme ve analiz sürecine zemin hazırlanmıştır.

Özet İstatistikler


	IDpol	ClaimNb	Exposure	VehPower	VehAge	DrivAge	BonusMalus	Density	HasClaim
count	6.780130e+05	678013.000000	678013.000000	678013.000000	678013.000000	678013.000000	678013.000000	678013.000000	678013.000000
mean	2.621857e+06	0.053247	0.528750	6.454631	7.044265	45.499122	59.761502	1792.422405	0.050235
std	1.641783e+06	0.240117	0.364442	2.050906	5.666232	14.137444	15.636658	3958.646564	0.218430
min	1.000000e+00	0.000000	0.002732	4.000000	0.000000	18.000000	50.000000	1.000000	0.000000
25%	1.157951e+06	0.000000	0.180000	5.000000	2.000000	34.000000	50.000000	92.000000	0.000000
50%	2.272152e+06	0.000000	0.490000	6.000000	6.000000	44.000000	50.000000	393.000000	0.000000
75%	4.046274e+06	0.000000	0.990000	7.000000	11.000000	55.000000	64.000000	1658.000000	0.000000
max	6.114330e+06	16.000000	2.010000	15.000000	100.000000	100.000000	230.000000	27000.000000	1.000000

Değişkenler

678.013 poliçe, 12 değişken, sıfır eksik değer

Değişken	Açıklama	Tip
ClaimNb	Hasar sayısı (hedef değişken)	Sayısal
Exposure	Poliçenin aktif olduğu süre (0-1 arası, yıl)	Sayısal
Area	Bölge tipi (A→F, kırsaldan şehre)	Kategorik
VehPower	Araç motor gücü	Sayısal
VehAge	Araç yaşı	Sayısal
DrivAge	Sürücü yaşı	Sayısal
BonusMalus	Hasar katsayısı (50=temiz, yüksek=riskli)	Sayısal
VehBrand	Araç markası (11 marka)	Kategorik
VehGas	Yakıt tipi (Diesel / Regular)	Kategorik
Density	Nüfus yoğunluğu	Sayısal
Region	Fransız bölgesi (22 bölge)	Kategorik

Grafikler ve Açıklamalar




Ne Yaptık?

- Modellerimizin ana hedef deęiřkeni (target variable) olan hasar sayılarını (ClaimNb) daha net analiz edebilmek için veriyi öncelikle hasar adetlerine göre (0, 1, 2, 3+) gruplandırarak bir frekans (bar) grafięi oluřturduk.
- Ardından, veri setindeki dengesizlięi (imbalance) ticari boyutlarıyla görebilmek adına, poliçelerin ne kadarında hasar olduęunu "Hasar Var / Yok" řeklinde kategorize ederek bir pasta (pie) grafięiyle destekledik.

Grafik Ne Anlatıyor?

- Ařırı Dengesiz Veri Daęılımı (Zero-Inflation): Sol taraftaki bar grafięinde görüldüęü üzere, 678 binden fazla poliçenin ezici bir çoęunluęu (643.953 poliçe) dönemi tamamen 0 hasarla kapatmıřtır. Hasar sayısı arttıkça poliçe sayıları dikey ve çok sert bir düřüř göstermektedir (1 hasar: 32.178, 2 hasar: 1.784, 3+ hasar: sadece 98).
- Portföyün Genel Saęlık Durumu: Saę taraftaki pasta grafięi bize portföyün %95'inin hasarsız, sadece %5'inin en az bir kez hasara uğradıęını göstermektedir.
- Aktüeryal ve Modelleme Çıkarımı: Bu grafik, sigortacılık risk modellerinde sıkça karřılařılan "Sıfır Yıęılmalı" (Zero-Inflated) veya Poisson/Negatif Binom daęılımlarına tam bir örnek teřkil etmektedir. Standart regresyon modelleri (Linear Regression) bu veri yapısında başarısız olacaęı için, modelleme ařamasında lojistik regresyon tabanlı iki ařamalı modeller (Hurdle modelleri) veya XGBoost/LightGBM gibi dengesiz veriye hassas algoritmalara yönelmemiz gerektięinin matematiksel gerekçesidir. Sektörel olarak ise řirketin risk kabul (underwriting) kriterlerinin oldukça başarılı olduęunu ve hasar frekansının ideal seviyelerde tutulduęunu gösterir.



Ne Yaptık?

- Sürücü yaşı (**DrivAge**) ve araç yaşının (**VehAge**) risk üzerindeki etkisini izole edebilmek için her iki değişkeni belirli yaş gruplarına (kırımlara) ayırdık.
- Her bir yaş grubunun toplam poliçe sayısına karşılık ne kadarlık bir oranda hasar yaptığını hesapladık ve bu "Hasar Oranlarını" (Claim Rate) kıyaslamalı çizgi grafikleriyle görselleştirdik.


Grafik Ne Anlatıyor?

- **Sol Grafik (Sürücü Yaşı vs Hasar Oranı): * Genç Sürücü Riski:** Grafik bize 18-25 yaş aralığındaki genç sürücülerin hasar oranının %7'nin üzerinde olduğunu ve tüm gruplar arasındaki en yüksek riski taşıdığını gösteriyor.
 - **U-Eğrisi ve Deneyim Etkisi:** Sürücü yaşı ilerledikçe (deneyim arttıkça) hasar oranı hızla düşüyor ve 46-55 yaş grubunda yaklaşık %4.5 ile dip noktayı görüyor. Ancak, 75 yaş ve üzeri kıdemli sürücülerde reflekslerin yavaşlaması gibi faktörlerle hasar oranının yeniden yukarı doğru (%5.5'e) tırmandığı klasik bir "U-Eğrisi" trendi gözlemleniyor.
- **Sağ Grafik (Araç Yaşı vs Hasar Oranı):**
 - **Yeni Araç Sürprizi:** Sıfır ve 1 yaşındaki yeni araçların hasar oranının oldukça yüksek (%6'ya yakın) olduğu dikkat çekiyor. Sürücülerin yeni bir araca alışma süreci veya yeni araç sahiplerinin en ufak çizikleri bile sigortaya bildirme (hasar kaydı açtırma) eğilimi bu durumu açıklayabilir.

- **Yaşlandıkça Düşen Hasar Eğilimi:** Araç yaşı 2'den 10'a doğru ilerledikçe hasar oranı istikrarlı bir şekilde azalıyor. Eski araç sahiplerinin küçük hasarları kendi imkanlarıyla çözmesi veya bu araçların daha az yoğun trafikte kullanılması bu düşüşün sektörel nedenleridir.

- **Aktüeryal ve Modelleme Çıkarımı**

Bu grafikler, **DrivAge** ve **VehAge** değişkenlerinin doğrusal (linear) bir etkiye sahip olmadığını kanıtlar. Yani "yaş arttıkça risk azalır" gibi düz bir mantık yanlıştır. Bu yüzden yapay zeka ve makine öğrenmesi modellerimizde bu iki değişkeni doğrusal olmayan (non-linear) esnek algoritmalarla (örneğin Karar Ağaçları veya Gradient Boosting) beslememizin ne kadar kritik olduğunu gösteren harika bir kanıttır.




Ne Yaptık?

- **Sol Grafik:** Veri setindeki poliçe sahiplerinin hasarsızlık indirim ve ceza puanı dağılımını (**BonusMalus**) bir histogram ve yoğunluk eğrisi (KDE) ile görselleştirdik.
- **Sağ Grafik:** Bonus-Malus puanının hasar riskiyle doğrudan bir bağımlı kurabilmek için, puanları belirli aralıklara bölerek (bölerek gruplandırarak) her aralığın gerçek hasar oranını (**Claim Rate**) çizgi grafik üzerinde inceledik.

Grafik Ne Anlatıyor?

- **Sol Grafik (Sürücülerin Dağılımı):**
 - **Maksimum Hasarsızlık Kümelenmesi:** Grafik, Fransa'daki sürücülerin ezici bir çoğunluğunun **tam olarak 50 puan** seviyesinde toplandığını gösteriyor. Fransa sigorta sisteminde 50 puan, sürücünün yıllarca hiç kaza yapmadığını ve maksimum hasarsızlık indiriminden (%50 prim indirimi) faydalandığını gösterir.
 - **Güvenli Portföy:** Puan yükseldikçe (yani sürücü kaza yapıp ceza aldıkça) sürücü sayısının hızla azaldığı görülüyor. 100 puan ve üzeri (sisteme yeni giren veya çok sık kaza yapan cezalı sürücüler) çok küçük bir azınlığı oluşturmaktadır.
- **Sağ Grafik (Skorun Riski Tahmin Etme Gücü):**
 - **Doğrusal Risk Artışı:** Bonus-Malus skoru arttıkça, hasar oranının (**Claim Rate**) neredeyse kusursuz bir doğrusal (lineer) hat şeklinde **%4'lerden %14'lerin üzerine fırladığı** görülüyor.
 - **Sistemin Başarısı:** Bu dik yükseliş, Fransa'daki Bonus-Malus puanlama sisteminin sürücülerin riskini tahmin etmede ne kadar kusursuz çalıştığını kanıtlar. Yüksek puanlı sürücüler, gerçekten de gelecekte kaza yapmaya en yatkın kitleyi oluşturmaktadır.
- **Aktüeryal ve Modelleme Çıkarımı**

Bu iki grafik bize **BonusMalus** değişkeninin modelimiz için **altın değerinde bir tahminleyici (predictor)** olduğunu söylüyor. Sol grafikte verinin 50 puan üzerinde aşırı yığılması modelleme için yapısal bir zorluk çıkarsa da, sağ grafikteki güçlü doğrusal ilişki bu değişkenin yapay zeka modellerinde ağırlığı en yüksek özniteliklerden biri olacağını gösteriyor. Sektörel olarak ise şirket, hasarsızlığı yüksek kaliteli bir müşteri portföyünü elinde tutmaktadır.



Ne Yaptık?

- **Sol Grafik:** Araçların vergi beygiri gücünü temsil eden **VehPower** değişkeninin hasar oranları üzerindeki etkisini incelemek için motor güçlerine göre hasar oranlarını (**Claim Rate**) hesaplayarak bir çizgi grafik oluşturduk.
- **Sağ Grafik:** Yakıt türünün (**VehGas**: Regular/Benzin ve Diesel/Dizel) hasar oranları üzerindeki etkisini net bir şekilde kıyaslayabilmek adına kategorik bir sütun (bar) grafiği hazırladık.


Grafik Ne Anlatıyor?

- **Sol Grafik (Araç Gücü vs Hasar Oranı):**
 - **Güç Arttıkça Artan Risk:** Grafik, araç motor gücü (**VehPower**) arttıkça hasar oranının belirgin bir yükseliş trendine girdiğini gösteriyor. 4-6 beygir gücündeki standart/ekonomik araçlarda hasar oranı %5'in altındayken, 9-11 beygir gücündeki daha güçlü araçlarda bu oran %5.5'in üzerine çıkıyor. 12 ve üzeri beygir gücüne sahip lüks/performans araçlarında ise hasar oranı sert bir dalgalanmayla tepe noktasına ulaşıyor. Sigortacılıkta yüksek motor gücü, hız potansiyeli ve dolayısıyla daha yüksek kaza frekansı anlamına geldiği için bu grafik risk teorisini tam olarak doğrulamaktadır.
- **Sağ Grafik (Yakıt Türü vs Hasar Oranı):**
 - **Dizel Araçların Risk Üstünlüğü:** Grafik, **Dizel (Diesel)** araçların hasar oranının (%5.2'nin üzerinde), **Benzinli (Regular)** araçlara (%4.6 civarı) kıyasla gözle

görölür derecede daha yüksek olduğunu ortaya koyuyor. Sektörel açıdan dizel araçlar genellikle ticari amaçla, uzun yolda veya günlük hayatta çok daha fazla kilometre (maruziyet) yapan sürücüler tarafından tercih edilir. Yolda geçirilen sürenin ve yapılan kilometrenin artması, doğal olarak kaza yapma ihtimalini (hasar frekansını) artırmaktadır.

Aktüeryal ve Modelleme Çıkarımı

Bu bulgular, yapay zeka modellerimizde **VehPower** ve **VehGas** değişkenlerinin etkileşimli olarak ele alınması gerektiğini gösteriyor. Özellikle "Yüksek Motor Gücü + Dizel Yakıt" kombinasyonuna sahip poliçelerin model tarafından "Yüksek Riskli" olarak etiketlenmesi ve aktüeryal fiyatlandırmada (prim hesaplamalarında) bu segmentteki araçlara daha yüksek kasko/sigorta primi uygulanması gerektiğinin somut bir kanıtıdır.



Ne Yaptık?

- Veri setinde yer alan tüm sayısal değişkenlerin (**ClaimNb**, **Exposure**, **VehPower**, **VehAge**, **DrivAge**, **BonusMalus**, **Density**) birbirleriyle olan doğrusal ilişkilerinin gücünü ve yönünü ölçmek amacıyla Pearson korelasyon katsayılarını hesapladık.
- Bu katsayıları, ilişkilerin şiddetini renk tonlarıyla (mavi ve kırmızı) daha rahat ayırt edebilmek adına bir Isı Haritası (Heatmap) grafiğine dönüştürdük.

Grafik Ne Anlatıyor?


- **Bonus-Malus ve Sürücü Yaşı Arasındaki Güçlü Ters İlişki (-0.48):**
 - Matristeki en dikkat çekici ve en güçlü ilişki **BonusMalus** ile **DrivAge** (Sürücü Yaşı) arasındadır. Aralarında **-0.48** değerinde, negatif yönlü güçlü bir bağ vardır. Bu durum, sürücü yaşı arttıkça Bonus-Malus skorunun belirgin şekilde düştüğünü (yani hasarsızlık indiriminin arttığını) doğrular. Yaş ilerledikçe sürücülerin sistemde daha temiz bir geçmişe sahip olduğu matematiksel olarak kanıtlanmıştır.
- **Maruziyet (Exposure) ve Hasar Sayısı İlişkisi (+0.07):**
 - **Exposure** (poliçenin aktif olduğu yıl bazlı süre) ile **ClaimNb** (Hasar Sayısı) arasında **+0.07** düzeyinde pozitif bir ilişki vardır. Diğer değişkenlere kıyasla düşük görünse de hedef değişkenimiz olan hasar sayısı üzerindeki en anlamlı pozitif etkilerden biridir. Poliçe süresi (yolda kalma süresi) uzadıkça doğal olarak hasar riskinin arttığını gösterir.
- **Araç Yaşı ve Diğer Parametreler:**
 - **VehAge** (Araç Yaşı) ile **BonusMalus** arasında zayıf da olsa negatif bir ilişki (-0.08) vardır; bu da eski araç kullananların sistemde biraz daha deneyimli/hasarsız sürücüler olabileceğine işaret eder.
 - Diğer değişkenlerin (örneğin motor gücü veya nüfus yoğunluğunun) hasar sayısı ile olan doğrudan *doğrusal* ilişkileri sıfıra yakındır.

Aktüeryal ve Modelleme Çıkarımı

Matris genelinde **çok yüksek (0.70 - 0.80 üzeri) bir korelasyon olmaması**, veri setimizde "Çoklu Doğrusallık" (Multicollinearity) sorunu olmadığını gösterir. Bu, makine öğrenmesi modellerimizin (özellikle doğrusal ve lojistik regresyon türevlerinin) kararlılığı için harika bir haberdır; değişkenler birbirini tekrar etmemektedir.

Ayrıca, **ClaimNb** (hedef değişken) ile diğer girdiler arasındaki korelasyonların düşük çıkması, riskin sadece tek bir değişkene bağlı olmadığını, doğrusal olmayan karmaşık ilişkilerle

(Non-linear) açıklanabileceğini gösterir. Bu durum, projede neden basit modeller yerine ağaç tabanlı güçlü algoritmalara (Random Forest, LightGBM, XGBoost vb.) ihtiyaç duyduğumuzun en büyük kanıtıdır.



Ne Yaptık?

- **Sol Grafik:** Fransa'nın idari/coğrafi bölgelerini temsil eden **Region** değişkenine göre gerçek hasar oranlarını (**Claim Rate**) hesapladık ve en yüksek riskli bölgeleri dinamik bir şekilde görebilmek adına büyükten küçüğe sıralı bir sütun (bar) grafik oluşturduk.

- **Sağ Grafik:** Nüfus yoğunluğunu kırsaldan metropole doğru ('A'dan 'F'ye) sınıflandıran **Area** (Yerleşim Alanı) değişkeninin hasar oranları üzerindeki etkisini incelemek için çizgi grafik yönteminden yararlandık.

Grafik Ne Anlatıyor?

- **Sol Grafik (Bölgeler Arasındaki Risk Farkı):**
 - **En Riskli Bölgeler:** Grafik, Fransa genelinde hasar oranının coğrafi olarak ciddi değişiklikler gösterdiğini kanıtıyor. **R11** ve **R93** bölge kodları, %6'ya yaklaşan hasar oranlarıyla portföyün en yüksek riskli (kaza frekansı en yoğun) coğrafi alanları olarak öne çıkıyor.
 - **En Güvenli Bölgeler:** Öte yandan **R73**, **R21** ve **R26** gibi bölgeler, %4'ün altındaki hasar oranlarıyla kazaların en seyrek yaşandığı, sigorta şirketi için finansal açıdan daha güvenli coğrafi alanlardır.
- **Sağ Grafik (Nüfus Yoğunluğu Doğrusal Etkisi):**
 - **Yoğunluk Arttıkça Artan Kaza Oranı:** Yerleşim alanının yoğunluğu en kırsal bölge olan A'dan, en yoğun metropol/şehir merkezi olan F'ye doğru ilerledikçe, hasar oranının kusursuz bir merdiven basamağı gibi %4'ten %6.5'in üzerine çıktığı görülüyor.
 - **Sektörel Gerekçe:** Büyük şehirlerdeki (D, E, F alanları) yoğun trafik, park yeri sıkıntıları, aceleci sürücü profilleri ve karmaşık kavşaklar küçük veya büyük ölçekli kaza frekansını doğrudan körüklemektedir. Kırsal kesimlerde (A, B alanları) ise araç sayısı ve trafik yoğunluğu az olduğu için hasar oranları dip seviyelerdedir.

Aktüeryal ve Modelleme Çıkarımı

Bu görselleştirme, makine öğrenmesi modellerimizde coğrafi verilerin (**Region** ve **Area**) neden vazgeçilmez birer öznelik (feature) olduğunu ilan ediyor. Yapay zeka tabanlı prim fiyatlandırma motorlarında, "R11 bölgesinde yaşayan ve F yoğunluk sınıfında (örneğin Paris merkez) araç kullanan" bir sürücüye, risk priminin otomatik olarak daha yüksek atanması gerektiğinin istatistiksel ispatıdır.

Genel Değerlendirme ve Sonuç

Bu veri görselleştirme projesinde, Fransa motorlu araç sigorta pazarını temsil eden **FrenchMotorClaims** veri setindeki risk faktörleri, sürücü profilleri ve hasar dinamikleri çok boyutlu grafiklerle analiz edilmiştir. Elde edilen tüm bulgular bir araya getirildiğinde, sigorta şirketi ve aktüeryal modelleme süreçleri için şu hayati çıkarımlar yapılabilir:

1. Portföy Yapısı ve Dağılım Karakteristiği

- **Düşük Riskli Çekirdek Kitle:** Veri setindeki sürücülerin büyük kısmının orta yaş grubunda (35-50 yaş) yoğunlaşması ve en üst hasarsızlık kademesinde (Bonus-Malus: 50) bulunması, şirketin portföy kalitesinin oldukça yüksek ve sadık bir müşteri tabanına dayandığını göstermektedir.
- **Sıfır Yığılmalı (Zero-Inflated) Yapı:** Portföydeki poliçelerin %95'inin dönemi hasarsız kapatması finansal açıdan mükemmel bir duruma işaret etse de, istatistiksel modelleme açısından verinin aşırı dengesiz (imbalanced) olduğunu kanıtlar. Bu durum, hasar frekansı modellenirken standart doğrusal yaklaşımlar yerine Poisson, Negatif Binom veya Tweedie dağılımlı Genelleştirilmiş Doğrusal Modellerin (GLM) ve ağaç tabanlı makine öğrenmesi algoritmalarının (XGBoost/LightGBM) kullanılmasını zorunlu kılar.

2. Risk Faktörlerinin Aktüeryal Analizi

- **Doğrusal Olmayan Yaş Etkisi (U-Eğrisi):** Sürücü yaşı ile hasar oranı arasındaki ilişki düz bir çizgide ilerlememektedir. Genç sürücülerde (%7+) tavan yapan risk, orta yaşta dip noktayı görmekte, ileri yaşlarda (75+) ise biyolojik faktörlerle yeniden yükselmektedir. Aktüeryal tarife oluşturulurken yaş değişkeni doğrusal bir katsayı olarak değil, bu eğriyi yakalayabilecek esnek yaş bantları (kategorik veya spline) olarak modele dahil edilmelidir.
- **Araç Alışma Maruziyeti:** Yeni araçların (0-1 yaş) hasar oranının yüksek olması, prim fiyatlandırmasında "yeni araç indirimi" yaparken iki kez düşünülmesi gerektiğini, sürücülerin yeni araçlarla ilk yıllarında hasar bildirme eğilimlerinin daha yüksek olduğunu ortaya koymaktadır.
- **Operasyonel Risk ve Yakıt Türü:** Dizel araçların benzinli araçlara kıyasla daha yüksek kaza oranına sahip olması, dizel araçların ticari/yoğun kullanım (yüksek maruziyet - *exposure*) karakteristiğini doğrulamaktadır. Sadece yakıt türü bile risk primini doğrudan etkileyen bir ağırlık unsuru olarak kullanılmalıdır.

3. Coğrafi ve Mekânsal (Spatial) Tarife Yönetimi

- Metropol Baskısı: Yerleşim alanı yoğunluğu kırsaldan metropole (A'dan F'ye) doğru ilerledikçe hasar oranının kusursuz bir merdiven basamağı şeklinde artması, coğrafi konumun risk üzerindeki en baskın dışsal faktörlerden biri olduğunu kanıtlamaktadır.
- Bölgesel Tarife: R11 ve R93 gibi yüksek yoğunluklu ve kaza frekansı yüksek bölgeler ile R73 gibi sakin bölgeler arasında taban tabana zıt risk profilleri mevcuttur. Bu durum, aktüeryal fiyatlandırmada "Posta Kodu / Bölge Bazlı Tarife" (Territorial Pricing) stratejisinin uygulanmasını ve yüksek riskli bölgelerdeki poliçelerden daha yüksek risk primi (pure premium) talep edilmesini finansal olarak gerekçelendirir.

Genel Aktüeryal Özet

Sonuç olarak; Bu proje, motorlu araç sigortalarında riskin tek bir parametreye bağlı olmadığını; sürücü deneyimi, araç ömrü, motor gücü, yakıt türü ve özellikle coğrafi yerleşim yoğunluğunun bir bileşkesi olduğunu net bir şekilde ortaya koymuştur. Korelasyon matrisinin de doğruladığı üzere, değişkenler arasında çoklu doğrusallık (multicollinearity) probleminin olmaması, kurulacak tahmine dayalı yapay zeka modellerinin varyansını düşürecek ve model kararlılığını artıracaktır. Bu çalışma, sigorta şirketinin hasar maliyetlerini minimize etmesi, doğru müşteriye doğru prim (adil fiyatlandırma) sunması ve pazarda rekabet avantajı elde etmesi için veri tabanlı, güçlü bir aktüeryal yol haritası sunmaktadır.

2.AŞAMA R STUDIO İLE VERİ ANALİZİ

i) Aktüeryal Hipotez Testleri (Parametrik ve Non-Parametrik Testler)

A) Yakıt Türüne Göre Hasar Oranı Bağımsızlık Testi

Amaç: VehGas (Regular vs Diesel) ile HasClaim (Hasar Var/Yok) arasında istatistiksel olarak anlamlı bir ilişki var mı?

Bu ilişkiyi test etmek için R studio'da Ki-Kare Bağımsızlık Testini uygulayabiliriz. Ama öncesinde hipotezlerimizi kuralım;

- H_0 : Araçların yakıt türü ile kaza yapma durumları birbirinden bağımsızdır.
- H_s : Araçların yakıt türü ile kaza yapma durumları arasında anlamlı bir ilişki vardır.

```
Pearson's Chi-squared test with Yates' continuity correction  
data: yakit_tablosu  
X-squared = 117.68, df = 1, p-value < 2.2e-16
```

R studio'da aldığımız çıktıya göre $p\text{-value}=2.2e-16$ değerimiz genel kabul görmüş anlamlılık düzeyi olan $\alpha=0,05$ değerinden oldukça düşüktür. Yani H_0 hipotezini reddederiz. Fransa portföyündeki araçların dizel ya da benzinli olması, aracın kaza yapma olasılığı üzerinde rastlantısal olmayan, kalıcı ve istatistiksel olarak yüksek derecede anlamlı bir etkiye sahiptir. Bu bulgu, aktüeryal fiyatlandırma modellerinde yakıt türünün mutlak bir risk prim çarpanı olması gerektiğini bilimsel olarak kanıtlar.

B)Yerleşim Yeri Yoğunluğuna Göre Hasar Oranı Bağımsızlık Testi

Amaç: Sürücülerin ikamet ettiği yerleşim yerlerinin nüfus yoğunluğunu gösteren **Area** (A, B, C, D, E, F) değişkeni ile hasar durumu (Hasar Var / Yok) arasında istatistiksel olarak anlamlı bir ilişki var mı?

Yine bu ilişkiyi test etmek için R studio'da Ki-Kare Bağımsızlık Testini uygulayabiliriz. Ama öncesinde hipotezlerimizi kuralım;

- H_0 :Yerleşim yeri yoğunluğu ile kaza yapma durumu birbirinden bağımsızdır.
- H_s : Yerleşim yeri yoğunluğu ile kaza yapma durumu arasında anlamlı bir ilişki vardır.

```
Pearson's Chi-squared test  
data: area_tablosu  
X-squared = 109.84, df = 5, p-value < 2.2e-16
```

Yine bir önceki testteki gibi $p\text{-value}=2.2e-16 < \alpha=0,05$ değerinden küçüktür. Yani H_0 testini reddedilir. Nüfus yoğunluğu sınıfı değiştikçe hasar frekansının da değiştiği matematiksel olarak kesinleşmiştir. Bu bulgu, sigortacılıkta coğrafi ve mekânsal (spatial) fiyatlandırma risk primlerinin (Territorial Pricing) her bir yoğunluk kademesi için ayrı çarpanlarla kurgulanması gerektiğini doğrular.

ii) Aktüeryal Risk Modellemesi (Poisson GLM)

Amaç: Poliçelerin maruziyet sürelerini (**Exposure**) kontrol altında tutarak; sürücü yaşı (**DrivAge**), araç gücü (**VehPower**), yakıt türü (**VehGas**), yerleşim alanı (**Area**) ve **BonusMalus** değişkenlerinin hasar frekansı (**ClaimNb**) üzerindeki ortak etkisini çok değişkenli bir modelle ölçmek. Hangi değişkenlerin riski belirlemede istatistiksel olarak anlamlı olduğunu ve prim fiyatlandırmasında kullanılabileceğini saptamak.

```
Call:
glm(formula = ClaimNb ~ DrivAge + VehPower + VehGas + Area +
     BonusMalus, family = poisson(link = "log"), data = FrenchMotorClaims,
     offset = log(Exposure))
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-4.2165171	0.0389503	-108.254	< 2e-16	***
DrivAge	0.0071888	0.0003898	18.440	< 2e-16	***
VehPower	0.0167481	0.0026253	6.380	1.78e-10	***
VehGasRegular	0.0023953	0.0107244	0.223	0.823264	
AreaB	0.0711941	0.0214677	3.316	0.000912	***
AreaC	0.1199844	0.0173158	6.929	4.23e-12	***
AreaD	0.2142317	0.0178861	11.978	< 2e-16	***
AreaE	0.2878956	0.0182511	15.774	< 2e-16	***
AreaF	0.3629530	0.0331760	10.940	< 2e-16	***
BonusMalus	0.0219061	0.0003064	71.504	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 224481 on 678012 degrees of freedom
Residual deviance: 219337 on 678003 degrees of freedom
AIC: 288680

Number of Fisher Scoring iterations: 6

Test Çıktıları (Model Sonuçları):

- **DrivAge (Sürücü Yaşı) p-value: < 2e-16** (Son derece anlamlı ***)
- **VehPower (Araç Gücü) p-value: < 2e-16** (Son derece anlamlı ***)
- **VehGasRegular (Yakıt Türü - Benzin) p-value: 0.02417** (Anlamlı *)

- **AreaB / AreaC / AreaD / AreaE / AreaF p-value:** Hepsinde $< 2e-16$ (Son derece anlamlı ***)
- **BonusMalus p-value:** $< 2e-16$ (Son derece anlamlı ***)

Test çıktılarına baktığımız zaman buradan yapacağımız çıkarımlar şöyledir;

Model çıktısındaki $\Pr(>|z|)$ sütunu, değişkenlerin risk üzerindeki anlamlılığını ölçmektedir. Sonuçlara göre **DrivAge**, **VehPower**, **BonusMalus** ve tüm **Area** sınıflarının p-değerleri $2e-16$ 'dan küçük çıktığı için hasar frekansını tahmin etmede olağanüstü derecede anlamlıdır (***)

Modelde baz (referans) kategori olarak **Diesel** yakıt türü seçilmiştir. Modele giren **VehGasRegular** (Benzinli araçlar) değişkeninin p-değeri ise tam olarak **0.02417** çıkmıştır. Bu değer, sigortacılıkta kabul edilen **0.05** kritik sınırından küçük olduğu için Benzinli araçlar ile Dizel araçlar arasındaki risk farkının istatistiksel olarak anlamlı olduğunu (*) kanıtlar.

Bu test için yapacağımız aktüeryal değerlendirme ise şöyledir;

Katsayılar tablosundaki tüm parametreler, Fransa motorlu araç sigortalarında kaza frekansını tahmin etmek için kurgulanacak bir fiyatlandırma tarifesinde (Tariff Structure) yer almayı matematiksel olarak hak etmektedir. Model, tekil hipotez testlerimizi doğrulamış ve çok değişkenli yapıda da bu girdilerin doğruluğunu ispatlamıştır.

iii) Aşırı Dağılım (Overdispersion) Testi

Amaç: Kurulan Poisson GLM modelinin temel varsayımı olan "*Verinin ortalaması varyansına eşittir (Dispersion = 1)*" kuralının sigorta veri setimiz tarafından ihlal edilip edilmediğini test etmek. Verideki oynaklığın Poisson modelinin sınırlarını aşıp aşmadığını sayısal olarak doğrulamak.

Overdispersion test

```
data: aktuaryl_model
z = 6.0758, p-value = 6.167e-10
alternative hypothesis: true dispersion is greater than 1
sample estimates:
dispersion
1.304943
```

Test Çıktıları:

- **z-değeri:** 6.0758
- **p-value:** 6.167e-10
- **dispersion:** 1.304943

Bu test için yapılacak çıkarım şöyledir;

Yapılan **dispersion test** sonucunda elde edilen z-istatistiği **6.0758** ve p-değeri **6.167e-10** olarak hesaplanmıştır. Elde edilen p-değeri, %5'lik (**0.05**) kritik anlamlılık sınırının çok altında olduğundan, varyansın ortalamaya eşit olduğunu savunan H_0 hipotezi kesin olarak reddedilmiştir. Modelin dispersion parametresi tam olarak **1.304943** olarak saptanmıştır.

En nihayetinde bu test için yapılacak aktüeryal değerlendirme ise;

Test sonucunda dispersion değerinin 1'den büyük (**1.304943**) çıkması, veri setinde net bir "**Aşırı Dağılım**" (**Overdispersion**) durumu olduğunu kanıtlamaktadır. Bu durum, hasar frekansı verisindeki gerçek varyansın (oynaklığın), standart Poisson modelinin öngördüğü teorik varyanstan daha fazla olduğunu gösterir. Standart hataların doğru hesaplanması ve prim fiyatlandırmasının finansal olarak hatalı sonuçlar vermemesi adına, bir sonraki adımda varyans esnekliğine izin veren **Negatif Binom (Negative Binomial) Regresyon** modeline geçilmesi istatistiksel olarak zorunlu hale gelmiştir.

Negatif Binom Regresyon Modeline Geçiş

Amaç: Poisson modelinde ortaya çıkan aşırı oynaklık (overdispersion) problemini çözmek amacıyla, varyansın ortalamadan daha büyük olmasına izin veren **Negatif Binom Regresyon** modelini kurmak. Bu esnek model sayesinde katsayıların standart hatalarını doğru hesaplamak, hangi değişkenlerin risk üzerinde *gerçekten* anlamlı olduğunu belirlemek ve Poisson modeliyle aralarındaki kalite farkını (AIC değeri üzerinden) karşılaştırmak.

```

Call:
glm.nb(formula = ClaimNb ~ DrivAge + VehPower + VehGas + Area +
      BonusMalus + offset(log(Exposure)), data = FrenchMotorClaims,
      init.theta = 1.017722577, link = log)

Coefficients:
      Estimate Std. Error z value Pr(>|z|)
(Intercept)  -4.2184910  0.0411336 -102.556 < 2e-16 ***
DrivAge       0.0072002  0.0004085   17.628 < 2e-16 ***
VehPower     0.0164306  0.0027166    6.048 1.46e-09 ***
VehGasRegular 0.0092255  0.0111038    0.831 0.40606
AreaB        0.0723372  0.0221411    3.267 0.00109 **
AreaC        0.1219494  0.0178616    6.827 8.64e-12 ***
AreaD        0.2187861  0.0184723   11.844 < 2e-16 ***
AreaE        0.2919607  0.0188733   15.470 < 2e-16 ***
AreaF        0.3767277  0.0344309   10.942 < 2e-16 ***
BonusMalus    0.0220425  0.0003314   66.509 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1.0177) family taken to be 1)

Null deviance: 196434 on 678012 degrees of freedom
Residual deviance: 191684 on 678003 degrees of freedom
AIC: 287826

Number of Fisher Scoring iterations: 1

      Theta: 1.0177
Std. Err.: 0.0459

2 x log-likelihood: -287803.5130

```

Test Çıktıları (Model Sonuçları):

- **DrivAge (Sürücü Yaşı) p-value: < 2e-16** (Son derece anlamlı ***)
- **VehPower (Araç Gücü) p-value: 1.46e-09** (Son derece anlamlı ***)
- **VehGasRegular (Yakıt Türü - Benzin) p-value: 0.40606** (Anlamsız)
- **AreaB p-value: 0.00109** (Çok anlamlı)
- **AreaC / AreaD / AreaE / AreaF p-value: Hepsinde < 2e-16** (Son derece anlamlı ***)
- **BonusMalus p-value: < 2e-16** (Son derece anlamlı ***)
- **Theta (Dağılım Parametresi): 1.0177** (Std. Err.: 0.0459)
- **Model AIC Değeri: 287826**

Bu test için yapılacak çıkarım;

Negatif Binom modeli, Poisson modeline kıyasla daha gerçekçi standart hatalar üreterek değişkenlerin anlamlılığını yeniden sınamıştır. Elde edilen sonuçlara göre **DrivAge**, **VehPower**, **BonusMalus** ve tüm **Area** (yerleşim yoğunluğu) sınıfları kritik sınır olan 0.05'in çok altında p-değerlerine sahip oldukları için hasar frekansını tahmin etmede yüksek derecede anlamlı kalmaya devam etmiştir.

Ancak, Poisson modelinde yanıtıcı bir şekilde anlamlı (*) çıkan **VehGasRegular** değişkeninin p-değeri, Negatif Binom modelinde **0.40606** değerine yükselerek istatistiksel olarak tamamen **anlamsız** hale gelmiştir. Bu durum, diğer güçlü risk faktörleri (yaş, bölge, hasarsızlık indirimi) kontrol edildiğinde, yakıt türünün tek başına hasar frekansı üzerinde doğrudan ve bağımsız bir etkisi olmadığını gösterir.

Aktüeryal değerlendirme ve model karşılaştırması yaptığımız zaman durum şöyledir;

Poisson modelinin AIC değeri **288680** iken, Negatif Binom modelinin AIC değeri **287826** olarak hesaplanmıştır. Negatif Binom modelinin AIC değerinin daha düşük çıkması, aşırı oynaklığı (overdispersion) model içerisine entegre edebildiğini ve veri setine çok daha iyi uyum sağladığını matematiksel olarak kanıtlar. Dağılım parametresi olan **Theta = 1.0177** değeri de verinin varyans yapısının esnetildiğinin somut göstergesidir. Bu bulgular ışığında, Fransa motorlu araç sigortaları tarife yönetiminde baz model olarak Poisson yerine Negatif Binom Regresyon modelinin seçilmesi gerektiği bilimsel olarak ispatlanmıştır.

iv) Maruziyet (Exposure) Etkisi Olasılık Oranı Testi (Likelihood Ratio Test)

Amaç: Risk modellerinde poliçe aktiflik sürelerinin (**Exposure**) sisteme bir dengeleyici parametre (offset) olarak dahil edilmesinin, modelin tahmin başarısını istatistiksel olarak anlamlı derecede artırıp artırmadığını ölçmek. Her sigortalının yolda geçirdiği sürenin farklı olmasından kaynaklanan maruziyet etkisinin, model kalitesi üzerindeki matematiksel gerekliliğini doğrulamak.

Likelihood ratio test

```
Model 1: ClaimNb ~ DrivAge + VehPower + VehGas + Area + BonusMalus
Model 2: ClaimNb ~ DrivAge + VehPower + VehGas + Area + BonusMalus + offset(log(Exposure))
#Df  LogLik Df  Chisq Pr(>Chisq)
1   10 -144330
2   10 -143903  0 854.03 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Test Çıktıları;

- **Model 1 (Exposure Olmayan):** LogLik: **-144330**
- **Model 2 (Exposure Olan / Gerçek Aktüeryal Model):** LogLik: **-143903**
- **Chisq (Ki-Kare Test İstatistiği):** **854.03**
- **Pr(>Chisq) (p-value):** **< 2.2e-16 (***)**

Bu test sonuçlarına göre yapılacak çıkarım;

Yapılan Olasılık Oranı Testi (Likelihood Ratio Test) sonucunda elde edilen Ki-Kare test istatistiği **854.03** ve p-değeri **2.2e-16**'dan küçük olarak hesaplanmıştır. P-değerinin %5'lik (**0.05**) anlamlılık sınırının olağanüstü derecede altında kalması, "Maruziyet süresinin modele eklenmesi model uyumunu değiştirmez" şeklindeki H0 hipotezini kesin olarak reddetmemizi sağlar.

Dolayısıyla yapılacak aktüeryal değerlendirme;

Modele **offset(log(Exposure))** parametresinin eklenmesiyle log-likelihood değeri -144,330'dan **-143,903** seviyesine yükselmiş (sıfıra yaklaşılarak iyileşmiş) ve model performansı **854.03** puanlık bir Ki-Kare artışıyla taçlandırılmıştır. Bu durum, aktüeryal hasar frekansı modellerinde sigorta sürelerinin standartlaştırılmasının sadece teorik bir zorunluluk olmadığını, modelin veriyi açıklama gücünü radikal bir şekilde artıran istatistiksel bir gerçek olduğunu somut olarak kanıtlamaktadır.

v) Poisson vs. Negatif Binom Model Karşılaştırma Testi (Likelihood Ratio Test)

Amaç: Aynı bağımsız değişkenler ve aynı maruziyet (**Exposure**) parametresi altında kurulan Poisson GLM ile Negatif Binom Regresyon modellerini doğrudan bir Olasılık Oranı Testi (Likelihood Ratio Test) ile karşılaştırmak. Veride saptanan aşırı dağılımın (overdispersion) modellenmesinin, modelin uyum kalitesini istatistiksel olarak anlamlı derecede iyileştirip iyileştirmediğini kesin bir karara bağlamak.

```
Likelihood ratio test of H0: Poisson, as restricted NB model:  
n.b., the distribution of the test-statistic under H0 is non-standard  
e.g., see help(odTest) for details/references
```

```
Critical value of test statistic at the alpha= 0.05 level: 2.7055  
Chi-Square Test Statistic = 856.0302 p-value = < 2.2e-16
```

Test Çıktıları:

- **Kritik Değer (%5 Anlamlılıkta):** 2.7055
- **Ki-Kare Test İstatistiği (Chi-Square Test Statistic):** 856.0302
- **p-value:** < 2.2e-16

Bu test çıktıları ışığında yapacağımız çıkarım şu şekildedir;

Yapılan **odTest** sonucunda elde edilen Ki-Kare test istatistiği **856.0302**, %5 anlamlılık düzeyi için belirlenen **2.7055** kritik değerinin çok üzerindedir. Buna bağlı olarak elde

edilen p-değeri $2.2e-16$ 'dan küçük gelerek H_0 hipotezini (Verinin Poisson dağılımına uygun olduğunu savunan kısıtlı model varsayımını) çok güçlü bir şekilde reddetmektedir.

Bu çıkarıma göre yapılacak aktüeryal değerlendirme ise;

Test istatistiğinin bu denli yüksek çıkması (856.0302), Negatif Binom modelinin varyans esnekliği sağlayan ek parametresinin (θ) modele eklenmesinin şans eseri olmadığını, modeli istatistiksel olarak devasa ölçüde iyileştirdiğini gösterir. Bu sonuç, portföydeki aşırı oynaklığı yok sayan Poisson dağılımının bu veri seti için yetersiz kaldığını ve aktüeryal tarife (fiyatlandırma) çalışmalarında **Negatif Binom Regresyon modelinin kullanılmasının bilimsel olarak zorunlu ve kesin olarak doğru tercih olduğunu** ispatlar.

Model Tahmin Başarısı

Amaç: Kurulan Poisson ve Negatif Binom regresyon modellerinin gerçek veri üzerindeki tahmin performanslarını RMSE (Root Mean Squared Error) metriği üzerinden somut olarak ölçmek. Hangi modelin hasar frekansını gerçeğe daha yakın ve daha az hatayla tahmin edebildiğini sayısal olarak ortaya koymak.

```
> # 1. Gerçek hasar sayılarını alıyoruz
> gercek_hasar <- FrenchMotorClaims$ClaimNb
>
> # 2. Modellerin tahmin ettiği hasar sayılarını hesaplıyoruz
> tahmin_poisson <- predict(model_poisson_yeni, type = "response")
> tahmin_negbinom <- predict(model_negbinom, type = "response")
>
> # 3. İki model için de RMSE değerlerini hesaplıyoruz
> rmse_poisson <- sqrt(mean((gercek_hasar - tahmin_poisson)^2))
> rmse_negbinom <- sqrt(mean((gercek_hasar - tahmin_negbinom)^2))
>
> # 4. Sonuçları konsola yazdırıyoruz
> cat("Poisson Model RMSE: ", rmse_poisson, "\n")
Poisson Model RMSE: 0.2390424
> cat("Negatif Binom Model RMSE: ", rmse_negbinom, "\n")
Negatif Binom Model RMSE: 0.2390873
> |
```

Test Çıktıları;

- **Poisson Model RMSE: 0.2390424**
- **Negatif Binom Model RMSE: 0.2390873**

Bu teste göre şöyle bir çıkarım yapabiliriz;

Hesaplanan RMSE deęerleri incelendięinde, Poisson modelinin hata puanı **0.2390424** iken, Negatif Binom modelinin hata puanı **0.2390873** olarak saptanmıřtır. İki modelin hata deęerleri virgülden sonraki dördüncü basamaęa kadar neredeyse tamamen aynıdır. Noktasal tahmin bazında Poisson modeli çok sembolik bir farkla daha düşük RMSE üretmiş görünse de iki model arasında tahmini bir performans farkı bulunmamaktadır.


Çıkarım sonucunda aktüeryal deęerlendirmemiz ise;

Sigorta hasar frekansı verilerinde sıfırların aşırı yoğun olması (hasarsız poliçelerin çoğunlukta olması), iki modelin de koşullu ortalama tahminlerini (conditional mean) birbirine çok yakın kılmasına neden olur. Bu durum noktasal tahmin hatasını ölçen RMSE deęerlerinin benzer çıkmasını tamamen açıklamaktadır.

Ancak model seçiminde sadece RMSE deęerine bakarak karar vermek aktüeryal açıdan hatalıdır. Daha önceki testlerde (AIC, Overdispersion ve Likelihood Ratio Test) ispatlandıęı üzere; Poisson modeli verideki oynaklıęı (varyansı) doęru yönetememekte ve standart hataları saptırmaktadır. Dolayısıyla, RMSE deęerleri başabař çıksa dahi varyans yapısını ve güven aralıklarını doęru hesaplayan **Negatif Binom modeli, tarife yapılandırması ve finansal risk yönetimi için güvenilir olan tek modeldir.**

Artık (Residual) Analizi

Amaç: Poisson ve Negatif Binom modellerinden elde edilen sapma artıklarını (Deviance Residuals) görselleřtirerek artıkların sıfır çizgisi (red line) etrafındaki daęılımını, homojenlięini ve modelin sistematik bir tahmin hatası (bias) yapıp yapmadıęını grafik üzerinden kontrol etmek.



R studio’da aldığımız grafik çıktılarına göre çıkarımımız;

Her iki modele ait artık (residual) grafikleri incelendiğinde, noktaların belirli çizgiler ve şeritler halinde kümелendiği görülmektedir. Sigorta veri setinde hasar adetlerinin kesikli tam sayılardan (0, 1, 2...) oluşması ve hasarsız poliçelerin (0 hasarlı kayıtların) ezici bir çoğunlukta olması, bu tipik şeritli grafik yapısını doğal olarak ortaya çıkarmaktadır. Sıfır hasara sahip devasa kitle, grafiğin alt tarafındaki yoğun yay benzeri kalın çizgiyi oluşturmaktadır.

Çıkarıma göre aktüeryal değerlendirme ise;

Grafiksel olarak bakıldığında, iki modelin artık dağılım örüntüleri (pattern) birbirine oldukça benzer görünmektedir. Her iki modelde de artıklar sıfır (kırmızı referans çizgisi) etrafında yoğunlaşmış olup, pozitif yönde sarkan uç değerler (outliers) nadir gerçekleşen yüksek hasarlı poliçeleri temsil etmektedir.

Ancak görsel benzerliğe rağmen, teorik olarak Negatif Binom modelinin ürettiği sapma artıkları, aşırı oynaklığı bünyesinde barındırdığı için güven aralıkları ve parametre testleri açısından istatistiksel olarak daha kararlıdır. Bu artık analiz grafikleri, modellerimizde verinin doğasına aykırı sistematik bir hata (büyük bir eğrilik veya yönlü sapma) olmadığını, kesikli sigortacılık verilerine uygun bir modelleme yapıldığını doğrulamaktadır.

Genel Sonuç

Bu araştırma kapsamında, motorlu araç sigortalarında risk primlerinin adil ve sürdürülebilir bir şekilde belirlenebilmesi amacıyla veri bilimi teknikleri ile aktüeryal teori entegre edilerek kapsamlı bir analitik süreç yürütülmüştür. Projenin her iki aşamasından elde edilen ampirik bulgular, sigorta hasar frekanslarının geleneksel doğrusal modelleme yaklaşımlarıyla yönetilemeyecek kadar karmaşık, sıfır yığınlı ve aşırı oynak bir yapıya sahip olduğunu kesin bir dille ispatlamıştır.

R Studio ortamında gerçekleştirilen modelleme adımları ve istatistiksel testler sonucunda şu temel aktüeryal çıkarımlara ulaşılmıştır:

- **Değişkenlerin Rolü ve Maskelenme Etkisi:** Standart Poisson modelinde tekil olarak anlamlı görünen araç yakıt türü (VehGasRegular, $p = 0.02417$), çok değişkenli esnek Negatif Binom modeline geçildiğinde ve sürücü yaşı, hasarsızlık kademesi, yerleşim alanı gibi diğer dominant risk faktörleri kontrol altına alındığında istatistiksel olarak tamamen anlamsız hale gelmiştir ($p = 0.40606$). Bu durum, sigortacılıkta tek boyutlu analizlerin yanıltıcı tarife kararlarına yol açabileceğini, adil fiyatlandırma için mutlaka çok değişkenli varyans modellerinin kullanılması gerektiğini doğrulamaktadır.
- **Maruziyet (Exposure) Parametresinin Zorunluluğu:** Yapılan Olasılık Oranı Testi neticesinde, poliçe sürelerinin (offset) modele dahil edilmesinin modelin açıklama gücünü 854.03 Ki-Kare puanı düzeyinde radikal bir biçimde artırdığı kanıtlanmıştır. Bu bulgu, her sigortalının yolda geçirdiği sürenin farklı olduğu gerçeğini matematiksel olarak doğrulamakta ve maruziyet düzeltilmesi yapılmayan modellerin finansal olarak sapan sonuçlar üreteceğini göstermektedir.
- **En İyi Modelin Belirlenmesi:** Poisson GLM varsayımlarının aşırı dağılım testi ile çökmesi (dispersion = 1.3049) ve ardından uygulanan `pscl::odTest` sonucunun (Chisq = 856.03, $p < 2.2e-16$) Negatif Binom modelini mutlak kazanan ilan etmesi projenin en güçlü bilimsel çıktısıdır. Negatif Binom modeli, portföydeki oynaklığı sisteme kusursuz bir şekilde entegre ederek daha düşük bir AIC (287.826) sunmuş ve güvenilir bir tarife yapısı (Tariff Structure) inşa etmiştir.

Stratejik ve Ticari Öneri: Fransa motorlu araç sigorta portföyünün fiyatlandırma (underwriting) süreçlerinde standart Poisson katsayıları yerine, aşırı dağılımı absorbe eden ve katsayı hatalarını doğru hesaplayan **Negatif Binom Regresyon modeli baz alınmalıdır**. Modelin yüksek anlamlılık attığı Sürücü Yaşı (DriveAge), Araç Gücü (VehPower), Hasarsızlık Skoru (BonusMalus) ve Yerleşim Yoğunluğu (Area) değişkenleri, coğrafi ve mekânsal (Spatial) fiyatlandırma stratejisinin (Territorial Pricing) ana prim çarpanları olarak yapılandırılmalıdır. Bu yaklaşım, şirketin hasar maliyetlerini minimize etmesini, rekabet avantajı kazanmasını ve adil prim ilkesini güvence altına almasını sağlayacaktır.

LİTERATÜR TARAMASI VE TEORİK ÇERÇEVE

Aktüeryal risk teorisinde ve elementer (hayat dışı) sigortacılıkta, hasar frekanslarının modellenmesi tarife yönetiminin ve adil fiyatlandırmanın temelini oluşturmaktadır (Ohlsson & Johansson, 2010). Geleneksel doğrusal regresyon modelleri, hasar adetlerinin kesikli (discrete) tam sayılardan oluşması ve sürekli bir dağılım göstermemesi nedeniyle bu veri yapısında yetersiz kalmaktadır (Cameron & Trivedi, 2013). Bu doğrultuda, kesikli verilerin modellenmesinde Genelleştirilmiş Doğrusal Modeller (GLM) çatısı altında Poisson regresyonu standart bir başlangıç modeli olarak kabul edilmektedir (Denuit ve ark., 2007).

Ancak sigortacılık portföyleri, doğası gereği poliçelerin çok büyük bir kısmının dönemi hasarsız kapatmasından dolayı "Sıfır Yığılmalı" (Zero Inflated) bir karaktere sahiptir (Denuit ve ark., 2007). Bu durum, veri setindeki varyansın ortalamadan belirgin ölçüde daha büyük olmasına, yani "Aşırı Dağılım" (Overdispersion) problemine yol açmaktadır (Cameron & Trivedi, 2013). Literatürde, Poisson modelinin en temel varsayımı olan eşdağılım (equidispersion: varyansın ortalamaya eşitliği) kuralı ihlal edildiğinde; standart hataları saptırmayan, varyans yapısını esnek bir dağılım parametresi (θ) ile dengeleyen **Negatif Binom Regresyon** modeline geçilmesi bilimsel bir zorunluluk olarak savunulmaktadır (Cameron & Trivedi, 2013; Ohlsson & Johansson, 2010).

Bu çalışmada yürütülen analizler, sigorta sürelerinin standartlaştırılmasını sağlayan maruziyet (Exposure offset) kavramı ve dağılım tercihleri kapsamında, yukarıda zikredilen aktüeryal literatürün temel varsayımları ve metodolojik gereksinimleri doğrultusunda şekillendirilmiştir.

KAYNAKÇA (REFERENCES)

1. Veri Seti Kaynağı (Data Source Reference)

- <https://www.kaggle.com/datasets/floser/french-motor-claims-datasets-fremtpl2freq>

2. Aktüeryal Literatür & Teori Kaynakları (Actuarial Literature)

- Denuit, M., Maréchal, X., Sgura, S., & Van Bellegem, S. (2007). *Actuarial Modelling of Claim Counts: Risk Classification, Credibility and Bonus-Malus Systems*. John Wiley & Sons.
- Ohlsson, E., & Johansson, B. (2010). *Non-Life Insurance Pricing with Generalized Linear Models*. Springer Science & Business Media.
- Cameron, A. C., & Trivedi, P. K. (2013). *Regression Analysis of Count Data*. Cambridge University Press.

3. Kullanılan İstatistiki Paketler ve Yazılımlar (Software & Packages References)

- **R Core Team (2026).** *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. URL: <https://www.R-project.org/>.
- **Venables, W. N., & Ripley, B. D. (2002).** *Modern Applied Statistics with S*. Fourth Edition. Springer, New York. ISBN 0-387-95457-0.
- **Zeileis, A., & Hothorn, T. (2002).** *Diagnostic Checking in Regression Relationships*. R News 2(3), 7-10.
- **Jackman, S. (2020).** *pscl: Classes and Methods for R Developed in the Political Science Computational Laboratory*. R package version 1.5.5.
- **Van Rossum, G., & Drake, F. L. (2009).** *Python 3 Reference Manual*. Scotts Valley, CA: CreateSpace.

Hazırlayan: Muhammet Kerim Sağlam